Redes Neuronales

Tarea 3: Dataset Computer Hardware

Realizado por: David Cevallos

Fecha: 2023-07-25

Enlace Google Colab: https://colab.research.google.com/drive/1TjaF2EfA5GJzp_5tPnFU9qOMSTCS9lks#scrollTo=KQs9zA4husbB

En esta tarea analizaremos el Dataset Computer Hardware a través de un árbol de regresión.

El dataset se encuentra disponible en: http://archive.ics.uci.edu/dataset/29/computer+hardware, posee 299 observaciones y 9 descriptores.

El laboratorio comprende dos partes. En la primera parte se construye un arbol de regresión considerando a la variable 1 (Vendor name) y descartando a la variable 2 (Model name), pues esta última no posee información de utilidad. En la segunda parte se descartan tanto la variable 1 como la variable 2. La idea principal es corroborar si la variable 1 contribuye al modelo.

```
# Importación de librerías
import pandas as pd
import numpy as np
import sklearn.metrics as mt
from sklearn import tree
from sklearn.model_selection import KFold
import matplotlib.pyplot as plt

# Función para asignación de valores numéricos a las
# categorías de la variable 1 (Vendor name)
def corregir(s):
  if s == "adviser":
    return 1
  elif s == "amdahl":
    return 2
  elif s == "apollo":
    return 3
  elif s == "basf":
    return 4
  elif s == "bti":
    return 5
  elif s == "burroughs":
    return 6
  elif s == "c.r.d":
    return 7
  elif s == "cambex":
    return 8
  elif s == "cdc":
    return 9
  elif s == "dec":
    return 10
  elif s == "dg":
    return 11
  elif s == "formation":
    return 12
  elif s == "four-phase":
    return 13
  elif s == "gould":
    return 14
  elif s == "harris":
    return 15
  elif s == "honeywell":
    return 16
  elif s == "hp":
    return 17
  elif s == "ibm":
    return 18
  elif s == "ipl":
    return 19
  elif s == "magnuson":
    return 20
  elif s == "microdata":
    return 21
  elif s == "nas":
```

```
    return 22
  elif s == "ncr":
    return 23
  elif s == "nixdorf":
    return 24
  elif s == "perkin-elmer":
    return 25
  elif s == "prime":
    return 26
  elif s == "siemens":
    return 27
  elif s == "sperry":
    return 28
  elif s == "sratus":
    return 29
  elif s == "wang":
    return 30

# Lectura de datos desde el archivo
data = pd.read_csv("/home/machine.data", header=None)

# Obtenemos las 30 categorías de la primera columna
print("Categorías de la primera columna")
print(np.unique(data[0]))

# Se asignan valores numéricos a variable 1 (Vendor name)
data[0] = data[0].map(lambda s: corregir(s))

```

```
Categorías de la primera columna
['adviser' 'amdahl' 'apollo' 'basf' 'bti' 'burroughs' 'c.r.d' 'cambex'
 'cdc' 'dec' 'dg' 'formation' 'four-phase' 'gould' 'harris' 'honeywell'
 'hp' 'ibm' 'ipl' 'magnuson' 'microdata' 'nas' 'ncr' 'nixdorf'
 'perkin-elmer' 'prime' 'siemens' 'sperry' 'sratus' 'wang']
```

```
# Función para cálculo de MSE medio a través de árbol de regresión
# y estrategia K-folding
# Parámetros:
# X Valores para predicción
# Y Valores de regresión
def calcularMSE(X, Y):
  num_folds = 10
  kfold = KFold(n_splits=num_folds, shuffle=True, random_state=0)
  total_mse = 0;

  for i, (train_index, test_index) in enumerate(kfold.split(X)):
    print("-------------------------------------------------")
    print("Resultados para Fold Nro.",str(i+1))
    print("-------------------------------------------------")
    # Definición y entrenamiento de árbol de regresión
    modelo = tree.DecisionTreeRegressor(criterion="squared_error",
                                        random_state=0,
                                        min_samples_leaf=15
                                        )
    modelo.fit(X[train_index,:], Y[train_index])
    # Obtención de valores predecidos para el fold (iteración)
    Ypred = modelo.predict(X[test_index,:])
    # Obtenemos el valor de MSE para el fold
    fold_mse = mt.mean_squared_error(Y[test_index], Ypred)
    print("Valor MSE = ", fold_mse)
    total_mse = total_mse + fold_mse;

    plt.figure(figsize=(8,4))
    plt.scatter(np.arange(1,len(Y[test_index])+1), Y[test_index], c="blue", marker="o", label="Reales")
    plt.scatter(np.arange(1,len(Ypred)+1), Ypred, c="red", marker="*", label="Predecidos")
    plt.title("Valores reales vs Valores predecidos (Test)")
    plt.legend(loc="best")
    plt.xticks(np.arange(1,len(Ypred)+1))
    plt.grid()
    plt.show()

    plt.figure(figsize=(15,8))
    tree.plot_tree(modelo, fontsize=7)
    plt.show()

  # Error Cuadrático Medio final
  mean_mse = total_mse/num_folds;
```

```
  print("-------------------------------------------------")
  print("Error Cuadrático Medio final: ", mean_mse);
  print("-------------------------------------------------")

```

```
# Parte 1: Árbol de regresión considerando la variable 1 (Vendor name) y
# y descartando la variable 2 (model name)
print("-------------------------------------------------")
print("Resultados Parte 1")
print("Considerando variable 1 y descartando variable 2")
print("-------------------------------------------------")
Y = data[9].to_numpy()
X = data.drop(columns=[1,9]).to_numpy()
calcularMSE(X,Y)
```

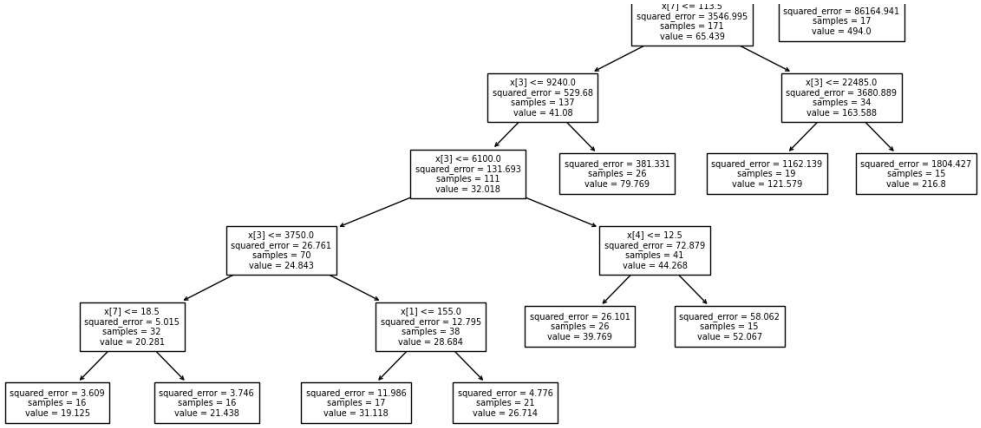


```
--------------------------------------------------
Resultados para Fold Nro. 10
--------------------------------------------------
Valor MSE =  57263.538602869085
```

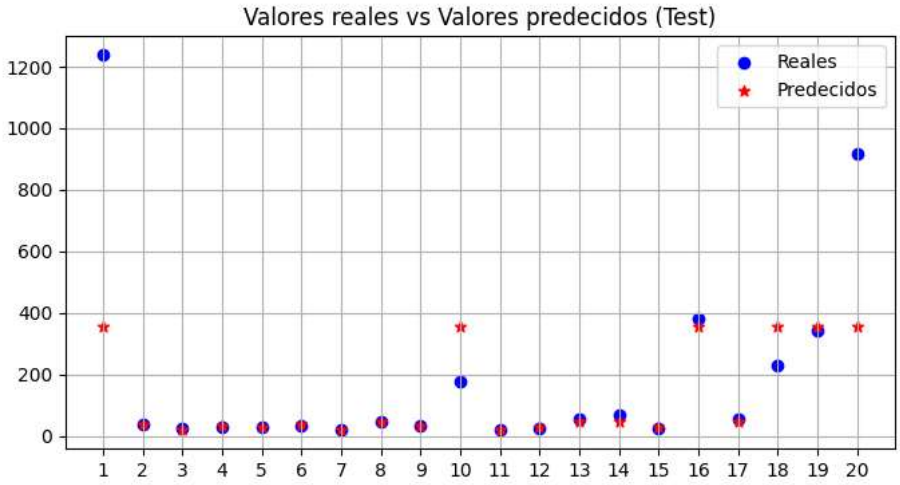

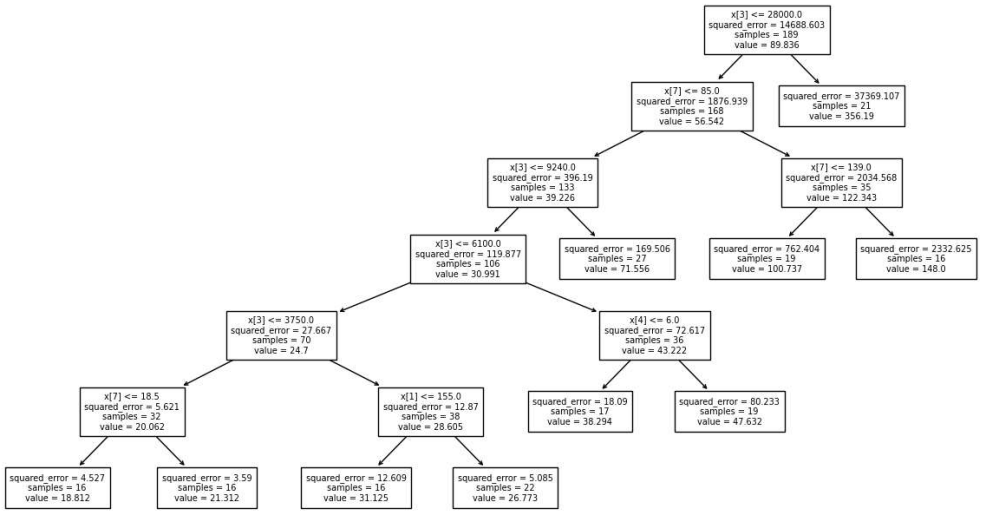


```
--------------------------------------------------
Error Cuadrático Medio final:  9748.467225101831
--------------------------------------------------
```